

数学基础—微积分

导师: Johnson

主要内容

微积分

P1:单变量微积分上(week3)

- 1.导数的定义与意义
- 2.常用函数的导数以及导数的常用公式, 复合函数求导
- 3.中值定理
- 4.洛必达法则
- 5.泰勒公式以及应用 🍏

P2:单变量微积分下(week3)

- 1.函数的凹凸性 🍏
- 2.函数的极值 🍏
- 3.不定积分
- 4.定积分

P3:多变量微积分(week3)

- 1.偏导数
- 2.多元复合函数的求导法则, 链式求导法则 🍏
- 3.方向导数与梯度及其应用 🍏
- 4.多元函数泰勒公式与海森矩阵
- 5.多元函数的极值
- 6.矩阵的求导 🍏
- 7.矩阵的求导在深度学习中的应用 🍒



主要内容

微积分

P1:单变量微积分上(week3)

- 1.导数的定义与意义
- 2.常用函数的导数以及导数的常用公式, 复合函数求导
- 3.中值定理
- 4.洛必达法则
- 5.泰勒公式以及应用 🍏

P2:单变量微积分下(week3)

- 1.函数的凹凸性 🍏
- 2.函数的极值 🍏
- 3.不定积分
- 4.定积分

P3:多变量微积分(week3)

- 1.偏导数
- 2.多元复合函数的求导法则, 链式求导法则 🍏
- 3.方向导数与梯度及其应用 🍏
- 4.多元函数泰勒公式与海森矩阵
- 5.多元函数的极值
- 6.矩阵的求导 🍏
- 7.矩阵的求导在深度学习中的应用 🍒



主要内容

微积分

P1:单变量微积分上(week3)

- 1.导数的定义与意义
- 2.常用函数的导数以及导数的常用公式, 复合函数求导
- 3.中值定理
- 4.洛必达法则
- 5.泰勒公式以及应用 🍏

P2:单变量微积分下(week3)

- 1.函数的凹凸性 🍏
- 2.函数的极值 🍏
- 3.不定积分
- 4.定积分

P3:多变量微积分(week3)

- 1.偏导数
- 2.多元复合函数的求导法则, 链式求导法则 🍏
- 3.方向导数与梯度及其应用 🍏
- 4.多元函数泰勒公式与海森矩阵
- 5.多元函数的极值
- 6.矩阵的求导 🍏
- 7.矩阵的求导在深度学习中的应用 🍒



主要内容

微积分

P1:单变量微积分上(week3)

- 1.导数的定义与意义
- 2.常用函数的导数以及导数的常用公式, 复合函数求导
- 3.中值定理
- 4.洛必达法则
- 5.泰勒公式以及应用 🍏

P2:单变量微积分下(week3)

- 1.函数的凹凸性 🍏
- 2.函数的极值 🍏
- 3.不定积分
- 4.定积分

P3:多变量微积分(week3)

- 1.偏导数
- 2.多元复合函数的求导法则, 链式求导法则 🍏
- 3.方向导数与梯度及其应用 🍏
- 4.多元函数泰勒公式与海森矩阵
- 5.多元函数的极值
- 6.矩阵的求导 🍏
- 7.矩阵的求导在深度学习中的应用 🍒



主要内容

微积分

P1:单变量微积分上(week3)

- 1.导数的定义与意义
- 2.常用函数的导数以及导数的常用公式, 复合函数求导
- 3.中值定理
- 4.洛必达法则
- 5.泰勒公式以及应用 🍏

P2:单变量微积分下(week3)

- 1.函数的凹凸性 🍏
- 2.函数的极值 🍏
- 3.不定积分
- 4.定积分

P3:多变量微积分(week3)

- 1.偏导数
- 2.多元复合函数的求导法则, 链式求导法则 🍏
- 3.方向导数与梯度及其应用 🍏
- 4.多元函数泰勒公式与海森矩阵
- 5.多元函数的极值
- 6.矩阵的求导 🍏
- 7.矩阵的求导在深度学习中的应用 🍒



主要内容

微积分

P1:单变量微积分上(week3)

- 1.导数的定义与意义
- 2.常用函数的导数以及导数的常用公式, 复合函数求导
- 3.中值定理
- 4.洛必达法则
- 5.泰勒公式以及应用 🍏

P2:单变量微积分下(week3)

- 1.函数的凹凸性 🍏
- 2.函数的极值 🍏
- 3.不定积分
- 4.定积分

P3:多变量微积分(week3)

- 1.偏导数
- 2.多元复合函数的求导法则, 链式求导法则 🍏
- 3.方向导数与梯度及其应用 🍏
- 4.多元函数泰勒公式与海森矩阵
- 5.多元函数的极值
- 6.矩阵的求导 🍏
- 7.矩阵的求导在深度学习中的应用 🍒





偏导数



定义 设函数 $z = f(x, y)$ 在点 (x_0, y_0) 的某一邻域内有定义，当 y 固定在 y_0 而 x 在 x_0 处有增量 Δx 时，相应的函数有增量

$$f(x_0 + \Delta x, y_0) - f(x_0, y_0),$$

如果

$$\lim_{\Delta x \rightarrow 0} \frac{f(x_0 + \Delta x, y_0) - f(x_0, y_0)}{\Delta x}, \quad (2-1)$$

存在，那么称此极限为函数 $z = f(x, y)$ 在点 (x_0, y_0) 处对 x 的偏导数，记作

$$\left. \frac{\partial z}{\partial x} \right|_{\substack{x=x_0 \\ y=y_0}}, \left. \frac{\partial f}{\partial x} \right|_{\substack{x=x_0 \\ y=y_0}}, z_x \Big|_{\substack{x=x_0 \\ y=y_0}} \text{ 或 } f_x(x_0, y_0).$$

类似地，函数 $z = f(x, y)$ 在点 (x_0, y_0) 处对 y 的偏导数定义为

$$\lim_{\Delta y \rightarrow 0} \frac{f(x_0, y_0 + \Delta y) - f(x_0, y_0)}{\Delta y}, \quad (2-3)$$

记作

$$\left. \frac{\partial z}{\partial y} \right|_{\substack{x=x_0 \\ y=y_0}}, \left. \frac{\partial f}{\partial y} \right|_{\substack{x=x_0 \\ y=y_0}}, z_y \Big|_{\substack{x=x_0 \\ y=y_0}} \text{ 或 } f_y(x_0, y_0).$$



偏导数

偏导数的概念还可推广到二元以上的函数

例如三元函数 $u = f(x, y, z)$ 在点 (x, y, z) 处对 x 的偏导数定义为

$$f_x(x, y, z) = \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x, y, z) - f(x, y, z)}{\Delta x}$$

例1 求 $z = x^2 + 3xy + y^2$ 在点 $(1, 2)$ 处的偏导数.

解 把 y 看做常量, 得 $\frac{\partial z}{\partial x} = 2x + 3y$;

把 x 看做常量, 得 $\frac{\partial z}{\partial y} = 3x + 2y$.

将 $(1, 2)$ 代入上面得结果, 就得

$$\left. \frac{\partial z}{\partial x} \right|_{\substack{x=1 \\ y=2}} = 2 \cdot 1 + 3 \cdot 2 = 8, \quad \left. \frac{\partial z}{\partial y} \right|_{\substack{x=1 \\ y=2}} = 3 \cdot 1 + 2 \cdot 2 = 7.$$

例2 求 $z = x^2 \sin 2y$ 的偏导数.

解 $\frac{\partial z}{\partial x} = 2x \sin 2y, \frac{\partial z}{\partial y} = 2x^2 \cos 2y$.

偏导数

设函数 $z = f(x, y)$ 在区域 D 内具有偏导数

$$\frac{\partial z}{\partial x} = f_x(x, y), \quad \frac{\partial z}{\partial y} = f_y(x, y),$$

于是在 D 内 $f_x(x, y), f_y(x, y)$ 都是 x, y 的函数. 如果这两个函数的偏导数也存在, 那么称它们是函数 $z = f(x, y)$ 的二阶偏导数. 按照对变量求导次序的不同有下列四个二阶偏导数:

$$\frac{\partial}{\partial x} \left(\frac{\partial z}{\partial x} \right) = \frac{\partial^2 z}{\partial x^2} = f_{xx}(x, y), \quad \frac{\partial}{\partial y} \left(\frac{\partial z}{\partial x} \right) = \frac{\partial^2 z}{\partial x \partial y} = f_{xy}(x, y),$$

$$\frac{\partial}{\partial x} \left(\frac{\partial z}{\partial y} \right) = \frac{\partial^2 z}{\partial y \partial x} = f_{yx}(x, y), \quad \frac{\partial}{\partial y} \left(\frac{\partial z}{\partial y} \right) = \frac{\partial^2 z}{\partial y^2} = f_{yy}(x, y).$$



偏导数

例3 设 $z = x^3y^2 - 3xy^3 - xy + 1$, 求 $\frac{\partial^2 z}{\partial x^2}$ 、 $\frac{\partial^2 z}{\partial y \partial x}$ 、 $\frac{\partial^2 z}{\partial x \partial y}$ 、 $\frac{\partial^2 z}{\partial y^2}$ 及 $\frac{\partial^3 z}{\partial x^3}$.

解 $\frac{\partial z}{\partial x} = 3x^2y^2 - 3y^3 - y$, $\frac{\partial z}{\partial y} = 2x^3y - 9xy^2 - x$;

$$\frac{\partial^2 z}{\partial x^2} = 6xy^2, \quad \frac{\partial^2 z}{\partial y \partial x} = 6x^2y - 9y^2 - 1;$$

$$\frac{\partial^2 z}{\partial x \partial y} = 6x^2y - 9y^2 - 1, \quad \frac{\partial^2 z}{\partial y^2} = 2x^3 - 18xy;$$

$$\frac{\partial^3 z}{\partial x^3} = 6y^2.$$



偏导数



定理 如果函数 $z = f(x, y)$ 的两个二阶混合偏导数 $\frac{\partial^2 z}{\partial y \partial x}$ 及 $\frac{\partial^2 z}{\partial x \partial y}$ 在区间 D 内连续, 那么在该区域内这两个二阶混合偏导数必相等.

$$z = x^3 y^2 - 3xy^3 - xy + 1$$


$$\frac{\partial^2 z}{\partial y \partial x} = 6x^2 y - 9y^2 - 1$$

$$\frac{\partial^2 z}{\partial x \partial y} = 6x^2 y - 9y^2 - 1$$



多元复合函数求导法则，链式求导法则

1. 一元函数与多元函数复合的情形

 **定理1** 如果函数 $u = \varphi(t)$ 及 $v = \psi(t)$ 都在点 t 可导，函数 $z = f(u, v)$ 在对应点 (u, v) 具有连续偏导数，那么复合函数 $z = f[\varphi(t), \psi(t)]$ 在点 t 可导，且有

$$\frac{dz}{dt} = \frac{\partial z}{\partial u} \frac{du}{dt} + \frac{\partial z}{\partial v} \frac{dv}{dt}.$$

例1 $z = f(u, v) = uv$ $u = e^t$ $v = \cos t$ 求 $\frac{dz}{dt}$.

解
$$\begin{aligned} \frac{dz}{dt} &= Z_u \frac{du}{dt} + Z_v \frac{dv}{dt} = v e^t + u(-\sin t) \\ &= \cos t \cdot e^t - e^t \sin t = e^t (\cos t - \sin t) \end{aligned}$$


链式求导很重要，
是深度学习的基础!!!





多元复合函数求导法则，链式求导法则

2. 多元函数与多元函数复合的情形

 **定理2** 如果函数 $u = \varphi(x, y)$ 及 $v = \psi(x, y)$ 都在点 (x, y) 具有对 x 及对 y 的偏导数，函数 $z = f(u, v)$ 在对应点 (u, v) 具有连续偏导数，那么复合函数 $z = f[\varphi(x, y), \psi(x, y)]$ 在点 (x, y) 的两个偏导数都存在，且有

$$\frac{\partial z}{\partial x} = \frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x}, \quad (4-3)$$

$$\frac{\partial z}{\partial y} = \frac{\partial z}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial y}. \quad (4-4)$$

例2 设 $z = e^u \sin v$ ，而 $u = xy$ ， $v = x + y$. 求 $\frac{\partial z}{\partial x}$ 和 $\frac{\partial z}{\partial y}$.

解
$$\frac{\partial z}{\partial x} = \frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x} = e^u \sin v \cdot y + e^u \cos v \cdot 1$$
$$= e^{xy} [y \sin(x + y) + \cos(x + y)],$$

$$\frac{\partial z}{\partial y} = \frac{\partial z}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial y} = e^u \sin v \cdot x + e^u \cos v \cdot 1$$
$$= e^{xy} [x \sin(x + y) + \cos(x + y)].$$



多元复合函数求导法则，链式求导法则

例3 设 $u = f(x, y, z) = e^{x^2+y^2+z^2}$, 而 $z = x^2 \sin y$. 求 $\frac{\partial u}{\partial x}$ 和 $\frac{\partial u}{\partial y}$.

解
$$\begin{aligned}\frac{\partial u}{\partial x} &= \frac{\partial f}{\partial x} + \frac{\partial f}{\partial z} \frac{\partial z}{\partial x} = 2xe^{x^2+y^2+z^2} + 2ze^{x^2+y^2+z^2} \cdot 2x \sin y \\ &= 2x(1 + 2x^2 \sin^2 y)e^{x^2+y^2+z^2}.\end{aligned}$$

$$\begin{aligned}\frac{\partial u}{\partial y} &= \frac{\partial f}{\partial y} + \frac{\partial f}{\partial z} \frac{\partial z}{\partial y} = 2ye^{x^2+y^2+z^2} + 2ze^{x^2+y^2+z^2} \cdot x^2 \cos y \\ &= 2(y + x^4 \sin y \cos y)e^{x^2+y^2+x^4 \sin^2 y}.\end{aligned}$$


例4 设 $z = f(u, v, t) = uv + \sin t$, 而 $u = e^t$, $v = \cos t$. 求全导数 $\frac{dz}{dt}$.

解
$$\begin{aligned}\frac{dz}{dt} &= \frac{\partial f}{\partial u} \frac{du}{dt} + \frac{\partial f}{\partial v} \frac{dv}{dt} + \frac{\partial f}{\partial t} = ve^t - u \sin t + \cos t \\ &= e^t \cos t - e^t \sin t + \cos t = e^t(\cos t - \sin t) + \cos t.\end{aligned}$$



方向导数与梯度及其应用

$$\begin{cases} x = x_0 + t \cos \alpha, \\ y = y_0 + t \cos \beta \end{cases} (t \geq 0).$$



$$\left. \frac{\partial f}{\partial l} \right|_{(x_0, y_0)} = \lim_{t \rightarrow 0^+} \frac{f(x_0 + t \cos \alpha, y_0 + t \cos \beta) - f(x_0, y_0)}{t}.$$

方向导数

$$\begin{aligned} & \lim_{t \rightarrow 0^+} \frac{f(x_0 + t \cos \alpha, y_0 + t \cos \beta) - f(x_0 + t \cos \alpha, y_0) + f(x_0 + t \cos \alpha, y_0) - f(x_0, y_0)}{t} \\ &= \lim_{t \rightarrow 0^+} \frac{f(x_0 + t \cos \alpha, y_0 + t \cos \beta) - f(x_0 + t \cos \alpha, y_0)}{t \cos \beta} \cos \beta \\ & \quad + \lim_{t \rightarrow 0^+} \frac{f(x_0 + t \cos \alpha, y_0) - f(x_0, y_0)}{t \cos \alpha} \cos \alpha. \end{aligned}$$

方向导数与梯度及其应用



定理 如果函数 $f(x, y)$ 在点 $P_0(x_0, y_0)$ 可微分, 那么函数在该点沿任一方向 l 的方向导数存在, 且有

$$\left. \frac{\partial f}{\partial l} \right|_{(x_0, y_0)} = f_x(x_0, y_0) \cos \alpha + f_y(x_0, y_0) \cos \beta .$$



方向导数与梯度及其应用

与方向导数有关联的一个概念是函数的梯度.在二元函数的情形, 设函数 $f(x, y)$ 在平面区域 D 内具有一阶连续偏导数, 则对于每一点 $P_0(x_0, y_0) \in D$, 都可定出一个向量

$$f_x(x_0, y_0)i + f_y(x_0, y_0)j,$$

这向量称为函数 $f(x, y)$ 在点 $P_0(x_0, y_0)$ 的梯度, 记作 $\text{grad} f(x_0, y_0)$ 或 $\nabla f(x_0, y_0)$, 即

$$\text{grad} f(x_0, y_0) = \nabla f(x_0, y_0) = f_x(x_0, y_0)i + f_y(x_0, y_0)j.$$

如果函数 $f(x, y)$ 在点 $P_0(x_0, y_0)$ 可微分, $e_l = (\cos \alpha, \cos \beta)$ 是与方向 l 同向的单位向量, 那么

$$\begin{aligned} \left. \frac{\partial f}{\partial l} \right|_{(x_0, y_0)} &= f_x(x_0, y_0) \cos \alpha + f_y(x_0, y_0) \cos \beta \\ &= \text{grad} f(x_0, y_0) \cdot e_l = |\text{grad} f(x_0, y_0)| \cos \theta \end{aligned}$$



方向导数与梯度及其应用

$$\begin{aligned}\left. \frac{\partial f}{\partial l} \right|_{(x_0, y_0)} &= f_x(x_0, y_0) \cos \alpha + f_y(x_0, y_0) \cos \beta \\ &= \text{grad} f(x_0, y_0) \cdot e_l = |\text{grad} f(x_0, y_0)| \cos \theta\end{aligned}$$

(1) 当 $\theta = 0$, 即方向 e_l 与梯度 $\text{grad} f(x_0, y_0)$ 的方向相同时, 函数 $f(x, y)$ 增加最快. 此时, 函数在这个方向的方向导数达到最大值, 这个最大值就是梯度 $\text{grad} f(x_0, y_0)$ 的模, 即

$$\left. \frac{\partial f}{\partial l} \right|_{(x_0, y_0)} = |\text{grad} f(x_0, y_0)|.$$

这个结果也表示: 函数 $f(x, y)$ 在一点的梯度 $\text{grad} f$ 是这样一个向量, 它的方向是函数在这点方向导数取得最大值的方向, 它的模就等于方向导数的最大值.

**梯度很重要,
是最优化的基础!!!**





方向导数与梯度及其应用

$$\begin{aligned}\left.\frac{\partial f}{\partial l}\right|_{(x_0, y_0)} &= f_x(x_0, y_0) \cos \alpha + f_y(x_0, y_0) \cos \beta \\ &= \operatorname{grad} f(x_0, y_0) \cdot e_l = |\operatorname{grad} f(x_0, y_0)| \cos \theta\end{aligned}$$

(2) 当 $\theta = \pi$, 即方向 e_l 与梯度 $\operatorname{grad} f(x_0, y_0)$ 的方向相反时, 函数 $f(x, y)$ 减少最快. 函数在这个方向的方向导数达到最小值, 即

$$\left.\frac{\partial f}{\partial l}\right|_{(x_0, y_0)} = -|\operatorname{grad} f(x_0, y_0)|.$$

(3) 当 $\theta = \frac{\pi}{2}$, 即方向 e_l 与梯度 $\operatorname{grad} f(x_0, y_0)$ 的方向正交时, 函数的变化率为零, 即

$$\left.\frac{\partial f}{\partial l}\right|_{(x_0, y_0)} = |\operatorname{grad} f(x_0, y_0)| \cos \theta = 0.$$

梯度很重要, 是最优化的基础!!!





方向导数与梯度及其应用

例1 设 $f(x, y) = \frac{1}{2}(x^2 + y^2)$, $P_0(1, 1)$, 求

- (1) $f(x, y)$ 在 P_0 处增加最快的方向以及 $f(x, y)$ 沿这个方向的方向导数;
- (2) $f(x, y)$ 在 P_0 处减少最快的方向以及 $f(x, y)$ 沿这个方向的方向导数;
- (3) $f(x, y)$ 在 P_0 处的变化率为零的方向.

解 (1) $f(x, y)$ 在 P_0 处沿 $\nabla f(1, 1)$ 的方向增加最快,

$$\nabla f(1, 1) = (xi + yj) \Big|_{(1,1)} = i + j,$$

故所求方向可取为

$$n = \frac{\nabla f(1, 1)}{|\nabla f(1, 1)|} = \frac{1}{\sqrt{2}}i + \frac{1}{\sqrt{2}}j,$$

方向导数为

$$\frac{\partial f}{\partial n} \Big|_{(1,1)} = |\nabla f(1, 1)| = \sqrt{2}.$$



方向导数与梯度及其应用

例1 设 $f(x, y) = \frac{1}{2}(x^2 + y^2)$, $P_0(1, 1)$, 求

- (1) $f(x, y)$ 在 P_0 处增加最快的方向以及 $f(x, y)$ 沿这个方向的方向导数;
- (2) $f(x, y)$ 在 P_0 处减少最快的方向以及 $f(x, y)$ 沿这个方向的方向导数;
- (3) $f(x, y)$ 在 P_0 处的变化率为零的方向.

(2) $f(x, y)$ 在 P_0 处沿 $-\nabla f(1, 1)$ 的方向减少最快,

这方向可取为

$$n_1 = -n = -\frac{1}{\sqrt{2}}i - \frac{1}{\sqrt{2}}j,$$

方向导数为

$$\left. \frac{\partial f}{\partial n_1} \right|_{(1,1)} = -|\nabla f(1, 1)| = -\sqrt{2}.$$



方向导数与梯度及其应用

例1 设 $f(x, y) = \frac{1}{2}(x^2 + y^2)$, $P_0(1, 1)$, 求

- (1) $f(x, y)$ 在 P_0 处增加最快的方向以及 $f(x, y)$ 沿这个方向的方向导数;
- (2) $f(x, y)$ 在 P_0 处减少最快的方向以及 $f(x, y)$ 沿这个方向的方向导数;
- (3) $f(x, y)$ 在 P_0 处的变化率为零的方向.

(3) $f(x, y)$ 在 P_0 处沿垂直于 $\nabla f(1, 1)$ 的方向变化率为零,
这方向是

$$n_2 = -\frac{1}{\sqrt{2}}i + \frac{1}{\sqrt{2}}j \quad \text{或} \quad n_3 = \frac{1}{\sqrt{2}}i - \frac{1}{\sqrt{2}}j.$$



方向导数与梯度及其应用

例2 设 $f(x, y, z) = x^3 - xy^2 - z$, $P_0(1, 1, 0)$. 问 $f(x, y, z)$ 在 P_0 处沿什么方向变化最快, 在这个方向的变化率是多少?

解 $\nabla f = f_x i + f_y j + f_z k = (3x^2 - y^2)i - 2xyj - k$, $\nabla f(1, 1, 0) = 2i - 2j - k$.

$f(x, y, z)$ 在 P_0 处沿 $\nabla f(1, 1, 0)$ 的方向增加最快, 沿 $-\nabla f(1, 1, 0)$ 的方向减少最快, 在这两个方向的变化率分别是

$$\begin{aligned} |\nabla f(1, 1, 0)| &= \sqrt{2^2 + (-2)^2 + 1} = 3, \\ -|\nabla f(1, 1, 0)| &= -3. \end{aligned}$$

求极值梯度下降法

$$\begin{aligned} &\min f(x) \\ x_{n+1} &= x_n - \lambda \nabla f(x_n) \end{aligned}$$



多元函数泰勒公式与海森矩阵



定理 设 $z = f(x, y)$ 在点 (x_0, y_0) 的某一邻域内连续且有 $(n + 1)$ 阶连续偏导数, $(x_0 + h, y_0 + k)$ 在此邻域内任一点, 则有

$$\begin{aligned} & f(x_0 + h, y_0 + k) \\ &= f(x_0, y_0) + \left(h \frac{\partial}{\partial x} + k \frac{\partial}{\partial y}\right) f(x_0, y_0) + \frac{1}{2!} \left(h \frac{\partial}{\partial x} + k \frac{\partial}{\partial y}\right)^2 f(x_0, y_0) + \cdots + \\ & \quad \frac{1}{n!} \left(h \frac{\partial}{\partial x} + k \frac{\partial}{\partial y}\right)^n f(x_0, y_0) + \frac{1}{(n+1)!} \left(h \frac{\partial}{\partial x} + k \frac{\partial}{\partial y}\right)^{n+1} f(x_0 + \theta h, y_0 + \theta k) \quad (0 < \theta < 1). \end{aligned}$$

其中记号

$$\left(h \frac{\partial}{\partial x} + k \frac{\partial}{\partial y}\right) f(x_0, y_0) \text{ 表示 } h f_x(x_0, y_0) + k f_y(x_0, y_0),$$

$$\left(h \frac{\partial}{\partial x} + k \frac{\partial}{\partial y}\right)^2 f(x_0, y_0) \text{ 表示 } h^2 f_{xx}(x_0, y_0) + 2hk f_{xy}(x_0, y_0) + k^2 f_{yy}(x_0, y_0)$$

一般地, 记号

$$\left(h \frac{\partial}{\partial x} + k \frac{\partial}{\partial y}\right)^m f(x_0, y_0) \text{ 表示 } \sum_{p=0}^m C_m^p h^p k^{m-p} \frac{\partial^m f}{\partial x^p \partial y^{m-p}} \Big|_{(x_0, y_0)}.$$



海森矩阵(二维或高维)

保留到二阶

$$\begin{aligned} f(x + \Delta x, y + \Delta y) &= f(x, y) + f_x \Delta x + f_y \Delta y + f_{xx} \Delta x^2 + 2f_{xy} \Delta x \Delta y + f_{yy} \Delta y^2 \\ &= f(x, y) + \begin{pmatrix} f_x \\ f_y \end{pmatrix}^T \begin{pmatrix} \Delta x \\ \Delta y \end{pmatrix} + (\Delta x, \Delta y) \begin{pmatrix} f_{xx} & f_{xy} \\ f_{xy} & f_{yy} \end{pmatrix} \begin{pmatrix} \Delta x \\ \Delta y \end{pmatrix} \end{aligned}$$

掌握海森矩阵!!!

更一般地

$$\begin{aligned} &f(x_1 + \Delta x_1, \dots, x_n + \Delta x_n) \\ &= f(x_1, \dots, x_n) + \begin{pmatrix} f_{x_1} \\ \vdots \\ f_{x_n} \end{pmatrix}^T \begin{pmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{pmatrix} + (\Delta x_1, \dots, \Delta x_n) \begin{pmatrix} f_{x_1 x_1} & \cdots & f_{x_1 x_n} \\ \vdots & \ddots & \vdots \\ f_{x_n x_1} & \cdots & f_{x_n x_n} \end{pmatrix} \begin{pmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{pmatrix} \\ &= f(x_1, \dots, x_n) + \nabla f^T \begin{pmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{pmatrix} + (\Delta x_1, \dots, \Delta x_n) H \begin{pmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{pmatrix} \end{aligned}$$

多元函数的极值

 **定义** 设函数 $z = f(x, y)$ 的定义域为 D , $P_0(x_0, y_0)$ 为 D 的内点. 若存在 P_0 的某个邻域 $U(P_0) \subset D$, 使得对于该邻域内异于 P_0 的任何点 (x, y) , 都有

$$f(x, y) < f(x_0, y_0),$$

则称函数 $f(x, y)$ 在点 (x_0, y_0) 有极大值 $f(x_0, y_0)$, 点 (x_0, y_0) 称为函数 $f(x, y)$ 的极大值点;
若对于该邻域内异于 P_0 的任何点 (x_0, y_0) , 都有

$$f(x, y) > f(x_0, y_0),$$

则称函数 $f(x, y)$ 在点 (x_0, y_0) 有极小值 $f(x_0, y_0)$, 点 (x_0, y_0) 称为函数 $f(x, y)$ 的极小值点.
极大值与极小值统称为极值. 使得函数取得极值的点称为极值点.



多元函数的极值



定理1 (必要条件) 设函数 $z = f(x, y)$ 在点 (x_0, y_0) 具有偏导数, 且在点 (x_0, y_0) 处有极值, 则有

$$f_x(x_0, y_0) = 0, f_y(x_0, y_0) = 0.$$



定理2 (充分条件) 设函数 $z = f(x, y)$ 在点 (x_0, y_0) 的某邻域内连续且有一阶及二阶连续偏导数, 又 $f_x(x_0, y_0) = 0, f_y(x_0, y_0) = 0$, 令

$$f_{xx}(x_0, y_0) = A, f_{xy}(x_0, y_0) = B, f_{yy}(x_0, y_0) = C,$$

则 $f(x, y)$ 在 (x_0, y_0) 处是否取得极值的条件如下:

- (1) $AC - B^2 > 0$ 时具有极值, 且当 $A < 0$ 时有极大值, 当 $A > 0$ 时有极小值;
- (2) $AC - B^2 < 0$ 时没有极值;
- (3) $AC - B^2 = 0$ 时可能有极值, 也可能没有极值, 还需另作讨论.



多元函数的极值

$$\begin{aligned} f(x_0 + \Delta x, y_0 + \Delta y) &= f(x_0, y_0) + \nabla f^T \Big|_{\substack{x=x_0 \\ y=y_0}} + (\Delta x, \Delta y) \begin{pmatrix} f_{xx} & f_{xy} \\ f_{xy} & f_{yy} \end{pmatrix} \begin{pmatrix} \Delta x \\ \Delta y \end{pmatrix} + \dots \\ &= f(x_0, y_0) + (\Delta x, \Delta y) \begin{pmatrix} f_{xx} & f_{xy} \\ f_{xy} & f_{yy} \end{pmatrix} \begin{pmatrix} \Delta x \\ \Delta y \end{pmatrix} + \dots \end{aligned}$$

①若H为正定, 则 $f(x_0 + \Delta x, y_0 + \Delta y) > f(x_0, y_0)$ 当 $\Delta x, \Delta y$ 比较小时,

$$\begin{aligned} \text{此时 } H &= \begin{pmatrix} A & B \\ B & C \end{pmatrix} \quad |H - \lambda I| = \begin{vmatrix} A - \lambda & B \\ B & C - \lambda \end{vmatrix} = (\lambda - A)(\lambda - C) - B^2 \\ &= \lambda^2 - (A + C)\lambda + AC - B^2 = 0. \end{aligned}$$

②若H为负定, 则 $f(x_0 + \Delta x, y_0 + \Delta y) < f(x_0, y_0)$

$$\begin{cases} \lambda_1 + \lambda_2 = A + C < 0 \\ \lambda_1 \lambda_2 = AC - B^2 > 0 \end{cases} \Rightarrow A < 0, C < 0, AC > B^2$$



矩阵的求导

1. $f(x) = Ax$, 则

$$\frac{\partial f(x)}{\partial x^T} = \frac{\partial (Ax)}{\partial x^T} = A$$

设 $A = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{pmatrix}$ $x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$

$$f = \begin{pmatrix} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 \end{pmatrix}$$

$$\frac{\partial f}{\partial X^T} = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \frac{\partial f_1}{\partial x_3} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \frac{\partial f_2}{\partial x_3} \end{pmatrix} = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{pmatrix} = A$$



矩阵的求导

2. $f(x) = x^T A x$, 则

$$\frac{\partial f(x)}{\partial x} = \frac{\partial (x^T A x)}{\partial x} = A x + A^T x$$

设 $x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$

$$f(x) = (x_1 \ x_2) \begin{pmatrix} a & b \\ c & d \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = a x_1^2 + (b + c) x_1 x_2 + d x_2^2$$

$$\frac{\partial f}{\partial x} = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \end{pmatrix} = \begin{pmatrix} 2 a x_1 + (b + c) x_2 \\ (b + c) x_1 + 2 d x_2 \end{pmatrix} = \left[\begin{pmatrix} a & b \\ c & d \end{pmatrix} + \begin{pmatrix} a & c \\ b & d \end{pmatrix} \right] \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = (A + A^T) x$$

特别地当A为对称矩阵时 $\frac{\partial f}{\partial x} = 2 A x$

矩阵的求导

3. $f(x) = a^T x$, 则

$$\frac{\partial a^T x}{\partial x} = \frac{\partial x^T a}{\partial x} = a$$

设 $a = \begin{pmatrix} a_1 \\ a_2 \end{pmatrix}$ $x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ $f = a_1 x_1 + a_2 x_2$

$$\frac{\partial f}{\partial x} = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \end{pmatrix} = \begin{pmatrix} a_1 \\ a_2 \end{pmatrix} = a \quad \frac{\partial f}{\partial a} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = x$$

$$\begin{aligned} J &= \|xa - y\|^2 && x \text{ 为 } N \times n, a \text{ 为 } n \times 1, \\ J &= (xa - y)^T (xa - y) && y \text{ 为 } N \times 1 \\ &= (a^T x^T - y^T)(xa - y) \\ &= a^T x^T xa - a^T x^T y - y^T xa + y^T y \end{aligned}$$

$$\frac{\partial (a^T x^T xa)}{\partial a} = 2x^T xa \quad \begin{matrix} y^T x \text{ 为 } 1 \times n, a \text{ 为 } n \times 1, \\ x^T y \text{ 为 } n \times 1 \end{matrix}$$

$$\frac{\partial (y^T xa)}{\partial a} = \frac{\partial [(x^T y)^T a]}{\partial a} = x^T y$$

$$\begin{aligned} a^T x^T y &= a^T (x^T y) && a \text{ 为 } n \times 1, x^T y \text{ 为 } n \times 1 \\ &= (x^T y)^T a = y^T xa \end{aligned}$$

$$\begin{aligned} \frac{\partial J}{\partial a} &= 2x^T xa - 2x^T y = 0 \\ x^T xa &= x^T y \end{aligned}$$



矩阵的求导

4. $f(x) = x^T A y$, 则

$$\frac{\partial x^T A y}{\partial x} = A y$$
$$\frac{\partial x^T A y}{\partial A} = x y^T$$

5. $\frac{\partial (\text{tr}(Z Z^T))}{\partial Z} = \frac{\partial (\text{tr}(Z^T Z))}{\partial Z} = 2Z$ Z 为 $m \times n$ Z^T 为 $n \times m$

$$\text{tr}(Z Z^T) = \sum_{i=1}^m d_{ii} = \sum_{i=1}^m \sum_{j=1}^n z_{ij} z_{ji}^T = \sum_{i=1}^m \sum_{j=1}^n z_{ij}^2$$

$$\frac{\partial (\text{tr}(Z Z^T))}{\partial Z} = \begin{pmatrix} 2z_{11} & \cdots & 2z_{1n} \\ \vdots & \ddots & \vdots \\ 2z_{m1} & \cdots & 2z_{mn} \end{pmatrix} = 2Z$$



矩阵的求导

$$\frac{\partial \text{tr}(A)}{\partial A} = I_{n \times n}$$
$$\frac{\partial \text{tr}(AB)}{\partial A} = B^T$$

$$\text{tr}(A) = \sum_{i=1}^n a_{ii} \quad A \text{ 为 } n \times n$$

A 为 $m \times n$,
 B 为 $n \times m$

$$\frac{\partial (\text{tr} A)}{\partial A} = \begin{pmatrix} 1 & & \\ & \ddots & \\ & & 1 \end{pmatrix} = I$$

$$\text{tr}(AB) = \sum_{i=1}^m d_{ii} = \sum_{i=1}^m \sum_{j=1}^n a_{ij} b_{ji}$$

$$\frac{\partial (\text{tr}(AB))}{\partial A} = \begin{pmatrix} b_{11} & \cdots & b_{n1} \\ \vdots & \ddots & \vdots \\ b_{1m} & \cdots & b_{nm} \end{pmatrix} = B^T$$

$$\frac{\partial |Z|}{\partial Z} = |Z| (Z^{-1})^T$$

$$\frac{\partial |Z|}{\partial Z_{ij}} = A_{ij}$$

$$|Z| = Z_{i1}A_{i1} + \cdots + Z_{ij}A_{ij} + \cdots + Z_{in}A_{in}$$


$$\frac{\partial |Z|}{\partial Z} = \begin{pmatrix} A_{11} & \cdots & A_{1n} \\ \vdots & \ddots & \vdots \\ A_{n1} & \cdots & A_{nn} \end{pmatrix} = Z^{*T}$$

$$Z^* Z = Z Z^* = |Z| E$$

$$Z^* = Z^{-1} |Z|$$

$$Z^{*T} = |Z| (Z^{-1})^T$$

矩阵的求导在深度学习中的应用(中级)



$W1$: $100 * 512$ 的矩阵

$W2$: $512 * 10$ 的矩阵

$$(x_1, x_2, \dots, x_{100})w_1 = (y_1, y_2, \dots, y_{512})$$

$$(z_1, z_2, \dots, z_{512})w_2 = (o_1, o_2, \dots, o_{10})$$

$$S_k = \frac{e^{o_k}}{\sum_{i=1}^{10} e^{o_i}}$$

$$J = -\ln S_k = J(w_1, w_2)$$

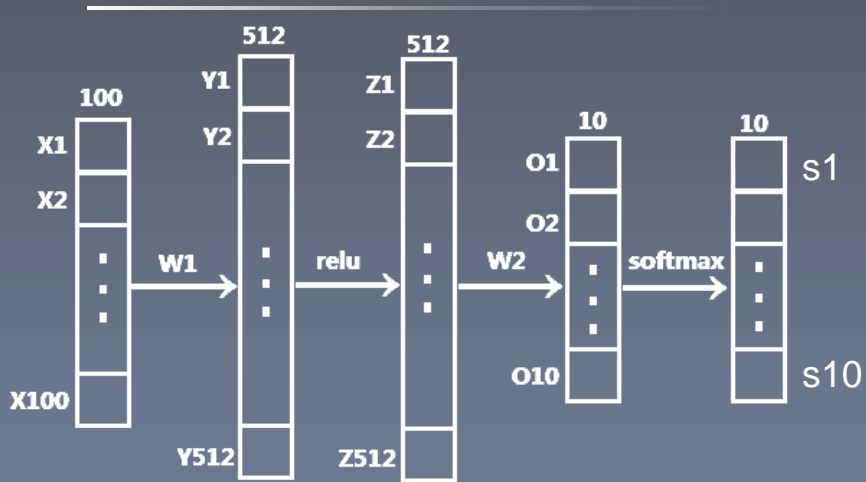
$$\frac{\partial J}{\partial o_m} = \frac{\partial (\ln \sum_{i=1}^{10} e^{o_i})}{\partial o_m} - \frac{\partial (\ln e^{o_k})}{\partial o_m}$$

$$= \frac{e^{o_m}}{\sum_{i=1}^{10} e^{o_i}} - \delta(m = k)$$

$$= S_m - \delta(m = k)$$

$$\frac{\partial J}{\partial O} = S - \tilde{S} \quad \text{其中 } \tilde{S} = (0, 0, \dots, \overset{k}{1}, 0, \dots, 0)$$

矩阵的求导在深度学习中的应用(中级)



$W1$: $100 * 512$ 的矩阵

$W2$: $512 * 10$ 的矩阵

$$\frac{\partial J}{\partial z_1} = \frac{\partial J}{\partial o_1} \frac{\partial o_1}{\partial z_1} + \frac{\partial J}{\partial o_2} \frac{\partial o_2}{\partial z_1} + \frac{\partial J}{\partial o_3} \frac{\partial o_3}{\partial z_1} = \frac{\partial J}{\partial o_1} w_{11} + \frac{\partial J}{\partial o_2} w_{12} + \frac{\partial J}{\partial o_3} w_{13}$$

$$\frac{\partial J}{\partial z_2} = \frac{\partial J}{\partial o_1} w_{21} + \frac{\partial J}{\partial o_2} w_{22} + \frac{\partial J}{\partial o_3} w_{23}$$

$$\frac{\partial J}{\partial Z} = \begin{pmatrix} \frac{\partial J}{\partial z_1} & \frac{\partial J}{\partial z_2} \end{pmatrix} = \begin{pmatrix} \frac{\partial J}{\partial o_1} & \frac{\partial J}{\partial o_2} & \frac{\partial J}{\partial o_3} \end{pmatrix} \begin{pmatrix} w_{11} & w_{21} \\ w_{12} & w_{22} \\ w_{13} & w_{23} \end{pmatrix} = \frac{\partial J}{\partial O} W^T$$

$$(x_1, x_2, \dots, x_{100}) W_1 = (y_1, y_2, \dots, y_{512})$$

$$(z_1, z_2, \dots, z_{512}) W_2 = (o_1, o_2, \dots, o_{10})$$

$$ZW = O \text{ 且 } \frac{\partial J}{\partial O} \Rightarrow \frac{\partial J}{\partial Z}, \frac{\partial J}{\partial W}$$

$$\text{为了简单: } Z = (z_1 \ z_2) \quad W = \begin{pmatrix} w_{11} & w_{12} & w_{13} \\ w_{21} & w_{22} & w_{23} \end{pmatrix} \quad O = (o_1 \ o_2 \ o_3)$$


$$o_1 = w_{11}z_1 + w_{21}z_2$$

$$o_2 = w_{12}z_1 + w_{22}z_2$$

$$o_3 = w_{13}z_1 + w_{23}z_2$$

$$\begin{aligned} \frac{\partial J}{\partial W} &= \begin{pmatrix} \frac{\partial J}{\partial o_1} z_1 & \frac{\partial J}{\partial o_2} z_1 & \frac{\partial J}{\partial o_3} z_1 \\ \frac{\partial J}{\partial o_1} z_2 & \frac{\partial J}{\partial o_2} z_2 & \frac{\partial J}{\partial o_3} z_2 \end{pmatrix} \\ &= \begin{pmatrix} z_1 \\ z_2 \end{pmatrix} \begin{pmatrix} \frac{\partial J}{\partial o_1} & \frac{\partial J}{\partial o_2} & \frac{\partial J}{\partial o_3} \end{pmatrix} = Z^T \frac{\partial J}{\partial O} \end{aligned}$$

矩阵的求导在深度学习中的应用(中级)



$W1$: $100 * 512$ 的矩阵
 $W2$: $512 * 10$ 的矩阵

$$(x_1, x_2, \dots, x_{100})w_1 = (y_1, y_2, \dots, y_{512})$$

$$(z_1, z_2, \dots, z_{512})w_2 = (o_1, o_2, \dots, o_{10})$$

$$\frac{\partial J}{\partial w_2} = Z^T \frac{\partial J}{\partial O}$$

$$\frac{\partial J}{\partial Z} = \frac{\partial J}{\partial O} w_2^T$$

$$Z = \text{relu}(Y)$$

$$z_i = \text{relu}(y_i)$$

$$\frac{\partial J}{\partial w_1} = X^T \frac{\partial J}{\partial Y}$$

$$\frac{\partial J}{\partial X} = \frac{\partial J}{\partial Y} w_1^T$$

$$\text{relu}(x) = \begin{cases} x, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

$$\frac{\partial J}{\partial y_i} = \frac{\partial J}{\partial z_i} \frac{\partial z_i}{\partial y_i} = \frac{\partial J}{\partial z_i} \begin{cases} 1, & y_i \geq 0 \\ 0, & y_i < 0 \end{cases}$$



deepshare.net

深度之眼

联系我们：

电话：18001992849

邮箱：service@deepshare.net

Q Q：2677693114



公众号



客服微信

