

# 数学基础—线性代数



导师: Johnson

---




# 主要内容

## 线性代数（下）




### P4:矩阵的初等变换

- 1.初等变换的引入
- 2.三种矩阵的初等变换以及对应的三种初等矩阵，矩阵的标准 
- 3.初等变换的常用性质与矩阵逆矩阵的另外一种简单求法
- 4.矩阵秩的定义以及性质
- 5.线性方程组解的个数
- 6.矩阵的秩在机器学习线性回归算法中的运用 

### P5:矩阵的特征值与特征向量

- 1.向量的线性相关，线性无关以及和可逆矩阵的关系 
- 2.向量的内积，范数，正交，规范正交基
- 3.施密特正交化
- 4.特征值和特征向量的定义以及直观的意义 
- 5.特征值与特征向量的求法以及常用性质 

### P6:矩阵对角化以及二次型

- 1.相似矩阵的定义以及矩阵的对角化
- 2.矩阵对角化的条件以及对称矩阵的对角化 
- 3.对角化在数据压缩算法中的应用
- 4.二次型与矩阵的正定性 
- 5.矩阵的正定性在机器学习线性回归算法中的运用 

### SVD分解及应用



- 1.SVD分解的证明上
- 2.SVD分解的证明上
- 3.SVD分解的应用:图像压缩算法
- 4.SVD分解的应用:深度学习的加速






# 主要内容

## 线性代数（下）




### P4:矩阵的初等变换

- 1.初等变换的引入
- 2.三种矩阵的初等变换以及对应的三种初等矩阵，矩阵的标准 
- 3.初等变换的常用性质与矩阵逆矩阵的另外一种简单求法
- 4.矩阵秩的定义以及性质
- 5.线性方程组解的个数
- 6.矩阵的秩在机器学习线性回归算法中的运用 

### P5:矩阵的特征值与特征向量

- 1.向量的线性相关，线性无关以及和可逆矩阵的关系 
- 2.向量的内积，范数，正交，规范正交基
- 3.施密特正交化
- 4.特征值和特征向量的定义以及直观的意义 
- 5.特征值与特征向量的求法以及常用性质 

### P6:矩阵对角化以及二次型

- 1.相似矩阵的定义以及矩阵的对角化
- 2.矩阵对角化的条件以及对称矩阵的对角化 
- 3.对角化在数据压缩算法中的应用
- 4.二次型与矩阵的正定性 
- 5.矩阵的正定性在机器学习线性回归算法中的运用 

### SVD分解及应用



- 1.SVD分解的证明上
- 2.SVD分解的证明上
- 3.SVD分解的应用:图像压缩算法
- 4.SVD分解的应用:深度学习的加速






# 主要内容

## 线性代数（下）




### P4:矩阵的初等变换

- 1.初等变换的引入
- 2.三种矩阵的初等变换以及对应的三种初等矩阵，矩阵的标准 
- 3.初等变换的常用性质与矩阵逆矩阵的另外一种简单求法
- 4.矩阵秩的定义以及性质
- 5.线性方程组解的个数
- 6.矩阵的秩在机器学习线性回归算法中的运用 

### P5:矩阵的特征值与特征向量

- 1.向量的线性相关，线性无关以及和可逆矩阵的关系 
- 2.向量的内积，范数，正交，规范正交基
- 3.施密特正交化
- 4.特征值和特征向量的定义以及直观的意义 
- 5.特征值与特征向量的求法以及常用性质 

### P6:矩阵对角化以及二次型

- 1.相似矩阵的定义以及矩阵的对角化
- 2.矩阵对角化的条件以及对称矩阵的对角化 
- 3.对角化在数据压缩算法中的应用
- 4.二次型与矩阵的正定性 
- 5.矩阵的正定性在机器学习线性回归算法中的运用 

### SVD分解及应用

- 1.SVD分解的证明上
- 2.SVD分解的证明上
- 3.SVD分解的应用:图像压缩算法
- 4.SVD分解的应用:深度学习的加速










# 主要内容

## 线性代数（下）




### P4:矩阵的初等变换

- 1.初等变换的引入
- 2.三种矩阵的初等变换以及对应的三种初等矩阵，矩阵的标准 
- 3.初等变换的常用性质与矩阵逆矩阵的另外一种简单求法
- 4.矩阵秩的定义以及性质
- 5.线性方程组解的个数
- 6.矩阵的秩在机器学习线性回归算法中的运用 

### P5:矩阵的特征值与特征向量

- 1.向量的线性相关，线性无关以及和可逆矩阵的关系 
- 2.向量的内积，范数，正交，规范正交基
- 3.施密特正交化
- 4.特征值和特征向量的定义以及直观的意义 
- 5.特征值与特征向量的求法以及常用性质 

### P6:矩阵对角化以及二次型

- 1.相似矩阵的定义以及矩阵的对角化
- 2.矩阵对角化的条件以及对称矩阵的对角化 
- 3.对角化在数据压缩算法中的应用
- 4.二次型与矩阵的正定性 
- 5.矩阵的正定性在机器学习线性回归算法中的运用 

### SVD分解及应用

- 1.SVD分解的证明上
- 2.SVD分解的证明上
- 3.SVD分解的应用:图像压缩算法
- 4.SVD分解的应用:深度学习的加速





# 向量的线性相关,线性无关以及与可逆矩阵的关系

## 线性相关与线性无关



**定义** 给定向量组  $A: a_1, a_2, \dots, a_m$ , 如果存在不全为零的数  $k_1, k_2, \dots, k_m$ , 使

$$k_1 a_1 + k_2 a_2 + \dots + k_m a_m = 0,$$

则称向量组  $A$  是线性相关的, 否则称它线性无关.

$a_1 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$   $a_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$  则  $a_1, a_2$  线性无关.

假设  $k_1 a_1 + k_2 a_2 = 0$

$$\Rightarrow k_1 \begin{bmatrix} 0 \\ 1 \end{bmatrix} + k_2 \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\Rightarrow k_1 = k_2 = 0$$

$a_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$   $a_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}$  则  $a_1, a_2$  线性相关.

假设  $k_1 a_1 + k_2 a_2 = 0$

$$\Rightarrow k_1 \begin{bmatrix} 1 \\ 2 \end{bmatrix} + k_2 \begin{bmatrix} 2 \\ 4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\Rightarrow \begin{cases} k_1 + 2k_2 = 0 \\ 2k_1 + 4k_2 = 0 \end{cases} \Rightarrow k_1 + 2k_2 = 0$$



# 向量的线性相关,线性无关以及与可逆矩阵的关系

## 线性相关与可逆的关系



**定理** 向量组  $a_1, a_2, \dots, a_m$  线性相关的充分必要条件是它所构成的矩阵  $A = (a_1, a_2, \dots, a_m)$

的秩小于向量个数  $m$ ; 向量组线性无关的充分必要条件是  $R(A) = m$ .

**例** 试讨论  $n$  维单位坐标向量组的线性相关性.

解:  $n$  维单位坐标向量组构成的矩阵

$$E = (e_1, e_2, \dots, e_n)$$

是  $n$  阶单位矩阵. 由  $|E| = 1 \neq 0$ , 知  $R(E) = n$ ,

即  $R(E)$  等于向量组中向量个数, 故由定理知,

此向量组是线性无关的.

# 向量的内积，范数，正交，规范正交基

## 内积

**定义** 设有 $n$ 维向量

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix},$$



令  $[x, y] = x_1y_1 + x_2y_2 + \cdots + x_ny_n$ ,  $[x, y]$ 称为向量 $x$ 与 $y$ 的内积.

内积是两个向量之间的一种运算，其结果是一个实数，用矩阵记号表示，当 $x$ 与 $y$ 都是列向量时，有

$$[x, y] = x^T y.$$

内积具有下列性质（其中 $x, y, z$ 为 $n$ 维向量， $\lambda$ 为实数）：

- (i)  $[x, y] = [y, x]$ ;
- (ii)  $[\lambda x, y] = \lambda[x, y]$ ;
- (iii)  $[x + y, z] = [x, z] + [y, z]$ ;
- (iv) 当 $x = 0$ 时， $[x, x] = 0$ ；当 $x \neq 0$ 时， $[x, x] > 0$ .

由这些定义加上我们中学在二维空间里面向量夹角的概念，我们可以推广到高维空间，也可以用来衡量高维空间中两个样本的相似度的一种度量(不同于欧式距离)

**柯西不等式**  $[x, y]^2 \leq [x, x][y, y]$ .

$\forall x, y \in R^n$ , 令  $z = x - \lambda y$ .

$$\begin{aligned} [z, z] &= [x - \lambda y, x - \lambda y] \\ &= [x, x] - 2\lambda[x, y] + \lambda^2[y, y] \geq 0 \quad \forall \lambda \end{aligned}$$

$$\Delta = 4[x, y]^2 - 4[x, x][y, y] \leq 0$$

$$[x, y]^2 \leq [x, x][y, y]$$

“=”条件为  $x = \lambda y$





# 向量的内积，范数，正交，规范正交基

## 范数与正交



**定义** 令  $\|x\| = \sqrt{[x, x]} = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}$ ,

$\|x\|$  称为  $n$  维向量  $x$  的长度 (或范数) .

当  $\|x\| = 1$  时, 称  $x$  为单位向量.

向量的长度具有下述性质:

(i) 非负性 当  $x \neq 0$  时,  $\|x\| > 0$ ; 当  $x = 0$  时,  $\|x\| = 0$ ;

(ii) 齐次性  $\|\lambda x\| = |\lambda| \|x\|$ ;

(iii) 三角不等式  $\|x + y\| \leq \|x\| + \|y\|$ .

当  $[x, y] = 0$  时, 称向量  $x$  与  $y$  正交. 显然, 若  $x = 0$ , 则  $x$  与任何向量都正交.



**定理** 若  $n$  维向量  $a_1, a_2, \cdots, a_r$  是一组两两正交的非零向量, 则  $a_1, a_2, \cdots, a_r$  线性无关.

二维欧式空间  
直观理解

# 向量的内积，范数，正交，规范正交基

## 规范正交基



**定义** 设 $n$ 维向量 $e_1, e_2, \dots, e_r$ 是向量空间 $V (V \subset \mathbb{R}^n)$ 的一个基，如果 $e_1, e_2, \dots, e_r$ 两两正交，且都是单位向量，则称 $e_1, e_2, \dots, e_r$ 是 $V$ 的一个规范正交基。

例如  $e_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \\ 0 \\ 0 \end{bmatrix}, e_2 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \\ 0 \\ 0 \end{bmatrix}, e_3 = \begin{bmatrix} 0 \\ 0 \\ \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}, e_4 = \begin{bmatrix} 0 \\ 0 \\ \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$  就是 $\mathbb{R}^4$ 的一个规范正交基。

若 $e_1, e_2, \dots, e_r$ 是 $V$ 的一个规范正交基，那么 $V$ 中任一向量 $a$ 应能由 $e_1, e_2, \dots, e_r$ 线性表示，设表示式为 $a = \lambda_1 e_1 + \lambda_2 e_2 + \dots + \lambda_r e_r$

### 思考

1. 二维空间的规范正交基有哪些
2. 如何求出这些表示的系数



# 施密特正交化

设  $a_1, \dots, a_r$  是向量空间  $V$  的一个基, 要求  $V$  的一个规范正交基. 这也就是要找一组两两正交的单位向量  $e_1, \dots, e_r$ , 使  $e_1, \dots, e_r$  与  $a_1, \dots, a_r$  等价. 这样一个问题, 称为把  $a_1, \dots, a_r$  这个基规范正交化.

我们可以用以下办法把  $a_1, \dots, a_r$  规范正交化: 取

$$b_1 = a_1;$$

$$b_2 = a_2 - \frac{[b_1, a_2]}{[b_1, b_1]} b_1;$$

... ..

$$b_r = a_r - \frac{[b_1, a_r]}{[b_1, b_1]} b_1 - \frac{[b_2, a_r]}{[b_2, b_2]} b_2 - \dots - \frac{[b_{r-1}, a_r]}{[b_{r-1}, b_{r-1}]} b_{r-1},$$

容易验证  $b_1, \dots, b_r$  两两正交, 且  $b_1, \dots, b_r$  与  $a_1, \dots, a_r$  等价.

然后只要把它们单位化, 即取

$$e_1 = \frac{1}{\|b_1\|} b_1, e_2 = \frac{1}{\|b_2\|} b_2, \dots, e_r = \frac{1}{\|b_r\|} b_r,$$

就是  $V$  的一个规范正交基.



# 施密特正交化

**例** 设  $a_1 = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix}$ ,  $a_2 = \begin{bmatrix} -1 \\ 3 \\ 1 \end{bmatrix}$ ,  $a_3 = \begin{bmatrix} 4 \\ -1 \\ 0 \end{bmatrix}$ , 试用施密特正交化过程把这组向量规范正交化.

**解** 取  $b_1 = a_1$ ;

$$b_2 = a_2 - \frac{[a_2, b_1]}{\|b_1\|^2} b_1 = \begin{bmatrix} -1 \\ 3 \\ 1 \end{bmatrix} - \frac{4}{6} \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} = \frac{5}{3} \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix};$$

$$b_3 = a_3 - \frac{[a_3, b_1]}{\|b_1\|^2} b_1 - \frac{[a_3, b_2]}{\|b_2\|^2} b_2 = \begin{bmatrix} 4 \\ -1 \\ 0 \end{bmatrix} - \frac{1}{3} \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} + \frac{5}{3} \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix} = 2 \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

再把它们单位化, 取

$$e_1 = \frac{b_1}{\|b_1\|} = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix}, e_2 = \frac{b_2}{\|b_2\|} = \frac{1}{\sqrt{3}} \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix}, e_3 = \frac{b_3}{\|b_3\|} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix},$$

$e_1, e_2, e_3$  即合所求.

# 施密特正交化



**定义** 如果 $n$ 阶矩阵 $A$ 满足  $A^T A = E$  (即 $A^{-1} = A^T$ ), 那么称 $A$ 为正交矩阵, 简称正交阵.

上式用 $A$ 的列向量表示, 即是

$$\begin{bmatrix} a_1^T \\ a_2^T \\ \vdots \\ a_n^T \end{bmatrix} (a_1, a_2, \dots, a_n) = E,$$

因为 $A^T A = E$ 与 $AA^T = E$ 等价, 所以上述结论对 $A$ 的行向量亦成立.

由此可见,  $n$ 阶正交阵 $A$ 的 $n$ 个列 (行) 向量构成向量空间 $\mathbb{R}^n$ 的一个规范正交基.

# 特征值和特征向量的定义以及直观的意义

Eigenvalues and eigenvectors

**定义** 设A是n阶矩阵，如果数 $\lambda$ 和n维非零列向量x使关系式

$$Ax = \lambda x \quad (1)$$



成立，那么，这样的数 $\lambda$ 称为矩阵A的特征值，非零向量x称为A的对应于特征值 $\lambda$ 的特征向量

刚开始讲矩阵的时候讲过矩阵对应的线性变换，如何从线性变换的角度去看这个问题

$$(A - \lambda E)x = 0 \quad \begin{vmatrix} a_{11} - \lambda & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} - \lambda & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} - \lambda \end{vmatrix} = 0$$

特征方程与特征多项式

$$(i) \lambda_1 + \lambda_2 + \cdots + \lambda_n = a_{11} + a_{22} + \cdots + a_{nn};$$

$$(ii) \lambda_1 \lambda_2 \cdots \lambda_n = |A|.$$

设 $\lambda = \lambda_i$ 为矩阵A的一个特征值，则由方程 $(A - \lambda_i E)x = 0$

可求得非零解 $x = p_i$ ，那么 $p_i$ 便是A的对应于特征值 $\lambda_i$ 的特征向量。



知识点



# 特征值与特征向量的求法以及常用性质

**例** 求矩阵  $A = \begin{pmatrix} 3 & -1 \\ -1 & 3 \end{pmatrix}$  的特征值和特征向量.

**解** A的特征多项式为

$$|A - \lambda E| = \begin{vmatrix} 3 - \lambda & -1 \\ -1 & 3 - \lambda \end{vmatrix} = (3 - \lambda)^2 - 1 = 8 - 6\lambda + \lambda^2 = (4 - \lambda)(2 - \lambda),$$

所以A的特征值为  $\lambda_1 = 2, \lambda_2 = 4$ .

当  $\lambda_1 = 2$  时, 对应的特征向量应满足

$$\begin{pmatrix} 3 - 2 & -1 \\ -1 & 3 - 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \text{ 即 } \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$

解得  $x_1 = x_2$ , 所以对应的特征向量可取为  $p_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ .

显然, 若  $p_i$  是矩阵A的对应于特征值  $\lambda_i$  的特征向量, 则  $kp_i (k \neq 0)$  也是对应于  $\lambda_i$  的特征向量.

# 特征值与特征向量的求法以及常用性质

**例** 求矩阵  $A = \begin{bmatrix} -1 & 1 & 0 \\ -4 & 3 & 0 \\ 1 & 0 & 2 \end{bmatrix}$  的特征值和特征向量.

**解** A的特征多项式为

$$|A - \lambda E| = \begin{vmatrix} -1-\lambda & 1 & 0 \\ -4 & 3-\lambda & 0 \\ 1 & 0 & 2-\lambda \end{vmatrix} = (2-\lambda)(1-\lambda)^2,$$

所以A的特征值为  $\lambda_1 = 2, \lambda_2 = \lambda_3 = 1$ .

当  $\lambda_1 = 2$  时, 解方程  $(A - 2E)x = 0$ .

$$\text{由 } A - 2E = \begin{bmatrix} -3 & 1 & 0 \\ -4 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix} \sim \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix},$$

$$\text{得基础解系 } p_1 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix},$$

所以  $k p_1 (k \neq 0)$  是对应于  $\lambda_1 = 2$  的全部特征向量.

当  $\lambda_2 = \lambda_3 = 1$  时, 解方程  $(A - E)x = 0$ . 由

$$A - E = \begin{bmatrix} -2 & 1 & 0 \\ -4 & 2 & 0 \\ 1 & 0 & 1 \end{bmatrix} \sim \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 2 \\ 0 & 0 & 0 \end{bmatrix},$$

得基础解系

$$p_2 = \begin{bmatrix} -1 \\ -2 \\ 1 \end{bmatrix},$$

所以  $k p_2 (k \neq 0)$  是对应于  $\lambda_2 = \lambda_3 = 1$  的全部特征向量.



# 特征值与特征向量的求法以及常用性质

**例** 求矩阵  $A = \begin{bmatrix} -2 & 1 & 1 \\ 0 & 2 & 0 \\ -4 & 1 & 3 \end{bmatrix}$  的特征值和特征向量.

**解**  $|A - \lambda E| = \begin{vmatrix} -2-\lambda & 1 & 1 \\ 0 & 2-\lambda & 0 \\ -4 & 1 & 3-\lambda \end{vmatrix} = (2-\lambda) \begin{vmatrix} -2-\lambda & 1 \\ -4 & 3-\lambda \end{vmatrix}$   
 $= (2-\lambda)(\lambda^2 - \lambda - 2) = -(\lambda+1)(\lambda-2)^2$

所以A的特征值为 $\lambda_1 = -1, \lambda_2 = \lambda_3 = 2$ .

当 $\lambda_1 = -1$ 时, 解方程 $(A + E)x = 0$ .由

$$A + E = \begin{bmatrix} -1 & 1 & 1 \\ 0 & 3 & 0 \\ -4 & 1 & 4 \end{bmatrix} \sim \begin{bmatrix} 1 & 0 & -1 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix},$$

得基础解系 $p_1 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$ ,

所以对应于 $\lambda_1 = -1$ 的全部特征向量为 $kp_1 (k \neq 0)$ .

当 $\lambda_2 = \lambda_3 = 2$ 时, 解方程 $(A - 2E)x = 0$ .由

$$A - 2E = \begin{bmatrix} -4 & 1 & 1 \\ 0 & 0 & 0 \\ -4 & 1 & 1 \end{bmatrix} \sim \begin{bmatrix} -4 & 1 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix},$$

得基础解系

$$p_2 = \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix}, p_3 = \begin{bmatrix} 1 \\ 0 \\ 4 \end{bmatrix},$$

所以对应于 $\lambda_2 = \lambda_3 = 2$ 的全部特征向量为  
 $k_2 p_2 + k_3 p_3$  ( $k_2, k_3$ 不同时为0)



# 特征值与特征向量的求法以及常用性质

**例** 设 $\lambda$ 是方阵 $A$ 的特征值，证明

(1)  $\lambda^2$ 是 $A^2$ 的特征值；

(2) 当 $A$ 可逆时， $\frac{1}{\lambda}$ 是 $A^{-1}$ 的特征值.

**证** 因 $\lambda$ 是 $A$ 的特征值，故有 $p \neq 0$ 使 $Ap = \lambda p$ . 于是

$$(1) \quad A^2 p = A(Ap) = A(\lambda p) = \lambda(Ap) = \lambda^2 p,$$

所以 $\lambda^2$ 是 $A^2$ 的特征值.

(2) 当 $A$ 可逆时，由 $Ap = \lambda p$ ，有 $p = \lambda A^{-1}p$ ，因 $p \neq 0$ ，知 $\lambda \neq 0$ ，故 $A^{-1}p = \frac{1}{\lambda}p$ ，

所以 $\frac{1}{\lambda}$ 是 $A^{-1}$ 的特征值.



按此例类推，不难证明：**若 $\lambda$ 是 $A$ 的特征值，则 $\lambda^k$ 是 $A^k$ 的特征值； $\varphi(\lambda)$ 是 $\varphi(A)$ 的特征值（其中 $\varphi(\lambda) = a_0 + a_1\lambda + \cdots + a_m\lambda^m$ 是 $\lambda$ 的多项式， $\varphi(A) = a_0E + a_1A + \cdots + a_mA^m$ 是矩阵 $A$ 的多项式）.**



# 特征值与特征向量的求法以及常用性质

**例** 设3阶矩阵A的特征值1, -1, 2, 求 $A^* + 3A - 2E$ 的特征值.

**解** 因A的特征值全不为0, 知A可逆,

故 $A^* = |A|A^{-1}$ . 而 $|A| = \lambda_1\lambda_2\lambda_3 = -2$ , 所以

$$A^* + 3A - 2E = -2A^{-1} + 3A - 2E.$$

把上式记作 $\varphi(A)$ , 有 $\varphi(\lambda) = -\frac{2}{\lambda} + 3\lambda - 2$ . 这里,  $\varphi(A)$ 虽不是矩阵多项式, 但也具有矩阵多项式的特性, 从而可得 $\varphi(A)$ 的特征值为 $\varphi(1) = -1$ ,  $\varphi(-1) = -3$ ,  $\varphi(2) = 3$ .



# 特征值与特征向量的求法以及常用性质



**定理** 设 $\lambda_1, \lambda_2, \dots, \lambda_m$ 是方程A的m个特征值,  $p_1, p_2, \dots, p_m$ 依次是与之对应的特征向量, 如果 $\lambda_1, \lambda_2, \dots, \lambda_m$ 各不相等, 则 $p_1, p_2, \dots, p_m$ 线性无关.

**例** 设 $\lambda_1$ 和 $\lambda_2$ 是矩阵A的两个不同的特征值, 对应的特征向量依次为 $p_1$ 和 $p_2$ ,

证明 $p_1 + p_2$ 不是A的特征向量.

**证** 按题设, 有 $Ap_1 = \lambda_1 p_1$ ,  $Ap_2 = \lambda_2 p_2$ , 故  $A(p_1 + p_2) = \lambda_1 p_1 + \lambda_2 p_2$ .

用反证法, 假设 $p_1 + p_2$ 是A的特征向量, 则应存在数 $\lambda$ , 使 $A(p_1 + p_2) = \lambda(p_1 + p_2)$ , 于是

$$\lambda(p_1 + p_2) = \lambda_1 p_1 + \lambda_2 p_2, \text{ 即 } (\lambda_1 - \lambda)p_1 + (\lambda_2 - \lambda)p_2 = 0,$$

因 $\lambda_1 \neq \lambda_2$ , 按定理知 $p_1, p_2$ 线性无关, 故由上式得 $\lambda_1 - \lambda = \lambda_2 - \lambda = 0$ , 即 $\lambda_1 = \lambda_2$ ,

与题设矛盾. 因此 $p_1 + p_2$ 不是A的特征向量.





深度之眼  
deepshare.net

联系我们：

电话：18001992849

邮箱：service@deepshare.net

Q Q：2677693114



公众号



客服微信

